

PROJETO DE ANÁLISE E PREVISÃO DA QUALIDADE DO AR NAS CAPITAIS BRASILEIRAS

Aluna: Ingryd Cristine Hidalgo Sella

RA: 10424934

Curso: Tecnologia em Ciência de Dados

Instituição: Universidade Presbiteriana Mackenzie

Entrega [2] – Referencial Teórico, Pipeline da Solução e Cronograma

1. REFERENCIAL TEÓRICO

A qualidade do ar constitui um importante problema ambiental e de saúde pública, principalmente nos grandes centros urbanos, onde fatores como circulação de veículos, atividades industriais, queimadas e condições meteorológicas podem contribuir para a concentração de poluentes atmosféricos. A Organização Mundial da Saúde (OMS) estabelece diretrizes para diferentes poluentes, incluindo material particulado fino (PM_{2,5}), material particulado inalável (PM₁₀), ozônio (O₃), dióxido de nitrogênio (NO₂), dióxido de enxofre (SO₂) e monóxido de carbono (CO), destacando a relação entre exposição à poluição atmosférica e impactos à saúde.

Nesse contexto, a análise de séries temporais apresenta-se como uma abordagem adequada para estudar a evolução dos níveis de poluição ao longo do tempo. Diferentemente de uma análise exclusivamente transversal, a série temporal permite considerar a ordem cronológica das observações, identificando tendências, padrões sazonais, ciclos e possíveis alterações no comportamento das variáveis. Dessa forma, informações históricas podem ser utilizadas para construir modelos capazes de estimar valores futuros.

Estudos recentes demonstram a aplicação de técnicas estatísticas e de Aprendizado de Máquina na previsão de material particulado, especialmente PM_{2,5}. Uma revisão publicada em 2025 apresenta diferentes abordagens para previsão de séries temporais de PM_{2,5}, contemplando métodos estatísticos, Machine Learning e Deep Learning, e destaca a utilização de métricas como erro absoluto médio na avaliação dos modelos.

Outra revisão recente analisou estudos de previsão e monitoramento da qualidade do ar baseados em Machine Learning e identificou a utilização de métodos como Random Forest e XGBoost para dados estruturados, além de técnicas de Deep Learning para captura de padrões espaço-temporais. O estudo também destaca desafios relacionados à generalização dos modelos, interpretabilidade e utilização em aplicações próximas do tempo real.

Para o presente projeto, serão consideradas inicialmente duas abordagens complementares. A primeira será baseada em modelos estatísticos de séries temporais, com possibilidade de utilização do ARIMA/SARIMA, capazes de representar dependências temporais e padrões de tendência e sazonalidade. A segunda utilizará algoritmos de Machine Learning, como Random Forest ou XGBoost, incorporando não somente valores históricos dos poluentes, mas também variáveis meteorológicas, como temperatura, umidade, precipitação e velocidade do vento.

A utilização de dados meteorológicos é particularmente relevante porque as condições atmosféricas podem influenciar a dispersão e a concentração de poluentes. O Instituto Nacional de Meteorologia (INMET) disponibiliza dados históricos de estações meteorológicas, incluindo informações horárias e diárias, por meio de seu Banco de Dados Meteorológicos e de suas ferramentas de consulta.

Assim, a proposta deste projeto consiste em construir e comparar modelos de previsão da qualidade do ar, avaliando seu desempenho por meio de métricas como MAE (Mean Absolute Error) e RMSE (Root Mean Squared Error). A comparação permitirá verificar como diferentes abordagens se comportam diante dos dados disponíveis, sem

pressupor previamente qual método apresentará melhor desempenho.

Além da contribuição técnica, o projeto apresenta caráter social e extensionista ao buscar transformar dados ambientais em informações acessíveis à população. A proposta está relacionada principalmente à ODS 11 – Cidades e Comunidades Sustentáveis, cujo Objetivo 11.6 prevê a redução do impacto ambiental das cidades, incluindo atenção específica à qualidade do ar e aos níveis de material particulado.

2. PIPELINE DA SOLUÇÃO

2.1. Coleta dos dados

A primeira etapa será a obtenção dos dados a partir de fontes primárias e oficiais. Serão priorizados dados meteorológicos do Instituto Nacional de Meteorologia (INMET), dados oficiais de monitoramento da qualidade do ar disponibilizados por órgãos ambientais, dados referentes às concentrações de poluentes e informações de data, horário e localização das estações. Os dados serão armazenados em arquivos estruturados, preferencialmente em formato CSV ou equivalente, mantendo as informações de origem para possibilitar a reprodução do experimento.

2.2. Integração das bases

Após a coleta, os conjuntos de dados serão integrados utilizando como referência temporal data, horário e estação/localidade. Essa etapa permitirá relacionar as concentrações de poluentes com as condições meteorológicas observadas no mesmo período.

2.3. Tratamento dos dados

Nesta etapa serão identificados e tratados valores ausentes, registros duplicados, valores inconsistentes, erros de medição, diferenças de unidade, problemas de formatação de datas e horários, períodos sem observações e possíveis valores extremos. Como se trata de uma série temporal, a ordem cronológica das observações será preservada, evitando vazamento temporal.

2.4. Análise exploratória temporal

Serão analisados tendência temporal, sazonalidade, comportamento diário, semanal e mensal, distribuição dos poluentes, correlação entre poluentes, relação entre poluentes e variáveis meteorológicas, períodos de maior concentração e possíveis anomalias. Serão utilizados gráficos de séries temporais, médias móveis, histogramas, gráficos de correlação e outras visualizações adequadas.

2.5. Engenharia de atributos

Para os modelos de Machine Learning, serão criadas variáveis derivadas da própria série temporal, como valores defasados, médias móveis, máximos e mínimos de períodos anteriores, hora do dia, dia da semana, mês, estação do ano e variáveis meteorológicas.

2.6. Divisão temporal dos dados

A base será dividida respeitando a ordem cronológica. Uma possibilidade inicial será utilizar aproximadamente 70% para treinamento, 15% para validação e 15% para

teste, com ajustes conforme a quantidade e periodicidade dos dados disponíveis. Os registros mais recentes serão mantidos para avaliação do modelo em situação semelhante à previsão de dados futuros.

2.7. Modelagem

Serão avaliadas pelo menos duas abordagens. A primeira utilizará um modelo estatístico de séries temporais, inicialmente ARIMA ou SARIMA. A segunda utilizará um algoritmo de Machine Learning, inicialmente Random Forest ou XGBoost, podendo incorporar informações históricas do poluente e variáveis meteorológicas. A escolha definitiva será realizada após a análise exploratória e avaliação da estrutura dos dados.

2.8. Avaliação dos modelos

Os modelos serão comparados por meio de métricas quantitativas, principalmente MAE e RMSE. O MAPE poderá ser utilizado quando sua aplicação for adequada à distribuição dos dados. Também serão comparados visualmente os valores reais e previstos, o comportamento dos erros, a capacidade de acompanhar tendências e o desempenho em períodos de maior concentração.


2.9. Produto analítico


O resultado final será apresentado por meio de um dashboard analítico contendo evolução histórica da qualidade do ar, indicadores por capital, gráficos temporais, variáveis meteorológicas, comparação entre valores observados e previstos, previsão para períodos futuros e indicadores de desempenho dos modelos.

2.10. Disponibilização pública

Como parte do caráter extensionista, os códigos, documentação e resultados serão organizados para permitir consulta e reprodução. A disponibilização poderá ocorrer por meio de um repositório contendo código-fonte, documentação, dicionário de dados, instruções de execução, modelos utilizados, resultados e dashboard ou visualização final.

3. REPRESENTAÇÃO DO PIPELINE





4. CRONOGRAMA DO PROJETO

Etapa	Atividade	Período	Resultado esperado
1	Definição do problema e escopo	Agosto/2026	Problema e objetivos definidos
2	Definição da equipe	Agosto/2026	Equipe formada
3	Levantamento das fontes de dados	Ago.-Set./2026	Fontes oficiais identificadas
4	Definição da base de dados	Ago.-Set./2026	Base principal selecionada
5	Pesquisa bibliográfica	Setembro/2026	Referências e trabalhos relacionados
6	Elaboração do Referencial Teórico	Setembro/2026	Fundamentação teórica
7	Definição do Pipeline	Setembro/2026	Arquitetura inicial da solução
8	Elaboração do cronograma	Setembro/2026	Planejamento das atividades
9	Entrega [2] - Referencial, Pipeline e Cronograma	28/09/2026	Entrega acadêmica
10	Coleta/download dos dados	Outubro/2026	Base bruta consolidada
11	Tratamento e limpeza dos dados	Outubro/2026	Base preparada

Etapas	Atividade	Período	Resultado esperado
12	Integração dos dados meteorológicos e ambientais	Outubro/2026	Base integrada
13	Análise exploratória	Outubro/2026	Padrões temporais identificados
14	Engenharia de atributos	Out.-Nov./2026	Variáveis para modelagem
15	Implementação do modelo estatístico	Novembro/2026	ARIMA/SARIMA implementado
16	Implementação dos modelos de Machine Learning	Novembro/2026	Modelos treinados
17	Validação e comparação dos modelos	Novembro/2026	Métricas calculadas
18	Ajustes e otimização	Novembro/2026	Modelos aprimorados
19	Desenvolvimento do dashboard	Nov.-Dez./2026	Produto analítico
20	Testes de reprodução	Dezembro/2026	Pipeline validado
21	Documentação do projeto	Dezembro/2026	Documento final
22	Organização do repositório público	Dezembro/2026	Código e documentação publicados
23	Preparação da apresentação	Dezembro/2026	Slides e roteiro
24	Apresentação do projeto	Conforme calendário	Apresentação ao cliente/banca

Observação: as etapas posteriores à entrega de 28/09/2026 foram planejadas como cronograma de desenvolvimento do produto e deverão ser ajustadas caso a disciplina estabeleça datas específicas para as entregas finais.

5. REFERÊNCIAS

INSTITUTO NACIONAL DE METEOROLOGIA (INMET). Banco de Dados Meteorológicos. Brasília, DF: Ministério da Agricultura e Pecuária. Disponível em: <https://bdmep.inmet.gov.br/>. Acesso em: 28 set. 2026.

INSTITUTO NACIONAL DE METEOROLOGIA (INMET). Dados meteorológicos e estações. Brasília, DF: Ministério da Agricultura e Pecuária. Disponível em: <https://tempo.inmet.gov.br/>. Acesso em: 28 set. 2026.

UNITED NATIONS. Goal 11: Sustainable Cities and Communities. United Nations Department of Economic and Social Affairs. Disponível em: <https://sdgs.un.org/goals/goal11>. Acesso em: 28 set. 2026.

WORLD HEALTH ORGANIZATION (WHO). WHO global air quality guidelines: particulate matter (PM2.5 and PM10), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide. Geneva: World Health Organization, 2021. Disponível em: <https://www.who.int/publications/i/item/9789240034228>. Acesso em: 28 set. 2026.

ROLE OF artificial intelligence and learning techniques in time series forecast of PM2.5 data: an extensive review. The Franklin Institute, 2025.

MACHINE learning for air quality prediction and data analysis: review on recent advancements, challenges, and outlooks. Science of the Total Environment, 2025.